



콘택트렌즈 색상 검사 시스템 개선 제안서

요약 (Executive Summary)

본 개선 제안서는 기존의 콘택트렌즈 인쇄/색상 품질 검사 시스템 개발 계획을 제3자의 시각에서 재평가하고 보완한 문서입니다. 컬러 콘택트렌즈의 인쇄 패턴과 색상을 머신비전으로 자동 검사하는 이 시스템은, 동심원 기반 색상 프로파일 분석과 LAB 색좌표 및 ΔE (색차) 기준을 활용하여 각 색상 영역의 품질을 판정하는 접근을 제안하고 있습니다. 기존 방식은 렌즈의 중심으로부터 반경 방향(r-프로파일)의 색상 변화를 분석함으로써, A(엣지), B(미들), C(인너) 각 잉크 영역과 그 혼합부위(A-B, B-C)의 색상 일관성을 정량화합니다. 이는 설계 대비 실제 제품의 색 편차를 ΔE 로 계산하여 OK/NG를 자동 판정하는 방식으로, 복잡한 딥러닝 모델에 의존하지 않는 현실적인 방법입니다.

개선안의 핵심 내용은 두 가지입니다. 첫째, 제안된 방식과 경쟁 또는 대안 기술(예: PatchCore, PaDiM, AutoEncoder 기반 이상 탐지, Diffusion 복원 기반 기법 등)을 면밀히 비교했습니다. 각 방법의 객관적인 장단점을 구현 난이도, 설명 가능성(XAI), 실시간 처리 성능, 단품종(SKU) 대응력 관점에서 평가하여, 왜 동심원 프로파일 기반 방식이 현 상황에 유리한지, 그리고 어떤 조건에서는 한계가 있을 수 있는지 분석합니다. 둘째, 실제 현장 도입을 위한 개발 로드맵과 필요한 리소스를 구체화했습니다. 성공적인 시스템 구현을 위해 필요 인력(예: ML/Vision 엔지니어, UI 개발자 등)과 개발 단계별 일정(1단계 프로토타입부터 4단계 현장 적용 준비까지)을 제시하고, PoC 단계에서 요구되는 샘플 데이터 수량과 장비 사양(카메라 해상도, 조명 조건 등)을 명시하였습니다. 또한 운영 중 단품종 렌즈 디자인에 대응하기 위한 SKU 관리 연동과, 향후 유지보수 방안도 포함했습니다.

결론적으로, 본 개선 제안서는 기존 계획의 도메인 특화 아이디어(동심원 색상 분석)의 강점을 유지하면서도, 최신 비전 이상 탐지 기술과의 비교를 통해 기술 선택의 타당성을 검증하고, 현실적인 개발 전략을 보완하였습니다. 이를 통해 본 프로젝트가 실질적인 사업 성과로 이어질 수 있도록, 보다 명확한 방향성과 실행 계획을 제시합니다.

1. 배경 및 기존 제안 개요

컬러 콘택트렌즈의 인쇄 품질 검사는 현재까지는 주로 육안 검사에 의존해왔으나, 사람의 감각에 의존하는 방법은 일관성 부족과 미세 결함 놓침의 문제가 있습니다. 본 프로젝트는 이를 해결하기 위해 머신비전 기반 자동화 시스템을 개발하고자 합니다. 기존 제안서에서 제시된 핵심 아이디어는 다음과 같습니다:

- **동심원 r-프로파일 기반 색상 분석:** 렌즈의 중심과 반경을 검출한 후 이미지를 극좌표계(r, θ)로 변환하여, 회전에 불변한 반지름 방향(r) 프로파일을 추출합니다. 렌즈를 얇은 동심원 링(annulus)들로 나누고 각 링의 평균 색상(RGB→LAB)을 계산하여, 반경에 따른 $L^* \cdot a^* \cdot b^*$ 곡선을 얻습니다. 이 프로파일로 렌즈의 색상 분포를 연속적으로 표현하며, 바깥쪽부터 순서대로 A(엣지 잉크), B(미들 잉크), C(인너 잉크) 영역과 A-B, B-C 혼합 영역의 색상 변화를 나타냅니다.
- **색상 Zone 분할 및 대표 색 추론:** r-프로파일 상의 변곡점(L^*, a^*, b^* 값 또는 ΔE 변화 급변 지점)을 찾아 그 위치(r 값)를 경계로 구간을 나눔으로써, 각 구간을 A, B, C 및 혼합 영역(A-B, B-C)으로 자동 분할합니다. 각 zone의 평균 LAB 값을 산출하여 해당 SKU(제품 디자인)별 기준 색상값으로 저장합니다. 혼합 zone에 대해서는 두 인접 잉크의 이론적 색 혼합 경로(예: A와 B 색상의 직선 연결상)에 대해 실제 색이 어느 정도 떨어지는지 확인함으로써, 잉크 번짐이나 그라데이션 품질을 평가합니다.
- **ΔE 기반 품질 판정:** 각 zone마다 목표 LAB 색상과 허용 색차(ΔE) 기준을 설정해 두고, 검사시 측정된 색상과 기준 색상 간의 ΔE (예: CIEDE2000 기준)를 계산합니다. ΔE 가 허용치를 넘는 zone이 한 군데라도 있으면 해당

렌즈를 불량(NG)으로 판정합니다. 혼합 zone의 경우에도, 실제 색상이 이상적으로 혼합되었을 때의 색 경로에서 크게 벗어나거나, 혼합 영역의 폭이 설계 대비 지나치게 넓거나 좁으면 품질 이상 신호로 간주합니다.

- **시스템 구현 계획:** 단일 이미지 처리를 위한 파이프라인과 모듈 구성이 제안되었습니다. OpenCV 기반 전처리 및 렌즈 위치 검출, r-profile 계산 모듈, 변곡점 기반 Zone 자동 분할 로직, ΔE 계산 및 품질 판정 모듈, SKU별 설정을 관리하는 SkuConfigManager, 결과 시각화 및 로깅 모듈 등이 포함됩니다. 개발은 4단계 로드맵으로 제시되었는데, 1) 알고리즘 프로토타입 구현, 2) zone 자동 설정 및 SKU 기준값 등록 기능, 3) 불량 검출 로직 고도화 (임계값 튜닝, 민감도/특이도 조정 등), 4) UI 구현 및 현장 도입 준비의 순서입니다.

요약하면, **동심원 색상 프로파일링**은 동심원 패턴 렌즈의 특성을 십분 활용하여, 비교적 간단한 규칙 기반 분석만으로 색상 품질 검사를 실현하려는 접근입니다. 이는 별도의 딥러닝 모델 학습 없이도 설정 값 조정을 통해 다양한 디자인 (SKU)에 대응 가능하고, 결과가 ΔE 수치로 제시되어 해석이 용이한 장점이 있습니다. 다음으로, 이러한 접근을 둘러싼 경쟁 기술들과의 비교 평가를 다룹니다.

2. 경쟁 기술 및 대안 기법 비교

콘택트렌즈 색상 검사 문제를 해결함에 있어, 본 프로젝트의 r-프로파일 기반 방식 이외에도 다양한 머신비전/딥러닝 기법들을 고려할 수 있습니다. 특히, 최근 제조분야 이상 탐지에는 딥러닝 기반 비지도 학습 기법들이 주목받고 있습니다. 여기서는 대표적인 대안으로 PaDiM, PatchCore, AutoEncoder 기반 재구성 기법, Diffusion 모델 기반 복원 기법을 선정하여 비교합니다. 각 접근 방식의 원리와 장단점을 표 1에 정리하고, 이어서 항목별로 설명합니다.

표 1. 콘택트렌즈 색상 검사 관련 주요 접근 방식 비교 (제안 방식 vs 대안 기술)

| 접근 방식 | 개요 및 원리 | 구현 난이도 | 설명가능성 (XAI) | 속도 (실시간성) | 다품종(SKU) 대응력 |
|------------------------|---|----------------------------|-----------------------------------|---------------------------------------|--|
| 동심원 r-프로파일 (제안) | 렌즈의 동심원 방향 색상 프로파일 분석으로 ΔE 기반 품질 판정. 도메인 지식 활용 규칙기반 검사. | 낮음: OpenCV 처리 및 수학적 계산 중심. | 높음: ΔE 수치 와 zone별 편차 등 결과 해석이 명확. | 매우 우수: ms 단위 연산으로 실시간 처리. | 높음: 신규 SKU는 샘플 몇 장으로 기준 등록, 추가 학습 불필요. |
| PaDiM (비지도 딥러닝) | Pretrained CNN 특징을 각 이미지 패치별로 추출, 패치 분포(정규분포) 모델링 후 벗어남 정도로 이상 판단 1 2 . | 중간: 사전학습모델 활용, 통계 계산 필요. | 보통: 이상 heatmap 제공 (패치 단위). | 양호: 비교적 연산량 적음 (공분산 계산), 수백 ms 이내 가능. | 제한적: SKU별 정상 샘플로 각기 분포 학습 필요. |

| 접근 방식 | 개요 및 원리 | 구현 난이도 | 설명가능성(XAI) | 속도(실시간성) | 다품종(SKU) 대응력 |
|-------------------------|---|--|--|--|--|
| PatchCore (비지도 딥러닝) | <p>Pretrained CNN 특징 중 대표 패치</p> <p>만 메모리 뱅크 (코어셋)에 저장, 입력 이미지 패치들과 최근접거리로 이상 판정 ③ . ④ . 높은 재현율 (Recall) 지향 ⑤ .</p> | <p>중간: Anomalib 등 오픈소스 활용 가능, 코어셋 알고리즘 이해 필요.</p> | <p>보통: 이상 부분을 heatmap으로 표시.</p> | <p>보통: 메모리 검색 연산 존재, 100~200ms/장 (GPU 사용시) ⑥ .</p> | <p>제한적: SKU별 정상 데이터로 개별 모델(메모리) 구성 필요.</p> |
| AutoEncoder (재구성 기반) | <p>렌즈 이미지를 인코딩/디코딩해 복원 오류로 이상 탐지 ⑦ . 정상 패턴은 잘 재구성되고 이상은 오차 발생.</p> | <p>낮음~중간: 구조 단순하지만 학습 데이터 확보 필요 ⑧ .</p> | <p>낮음: 복원차이 시각화 가능하나 모델 내부는 블랙박스.</p> | <p>양호: 소형 AE 모델은 실시간 가능, 단 해상도 높으면 어려움.</p> | <p>낮음: SKU별로 별도 모델 학습 또는 복잡한 다중패턴 학습 필요.</p> |
| Diffusion 복원 (최신 기법) | <p>Diffusion 생성 모델로 정상 패턴을 고해상도로 복원, 입력과의 차이를 통해 미세 이상 검출. 최신 연구들에서 최고 성능 시현 ⑨ .</p> | <p>높음: 모델 훈련 복잡, 속도 개선 위한 추가 연구 필요 ⑩ .</p> | <p>낮음: 생성 모델 내부 판단 근거는 불투명, 차이 이미지만 활용.</p> | <p>낮음: 일반 Diffusion은 단계 샘플링으로 느림 (초당 수장 이하). ※ One-step 개선 연구 진행 ⑪ .</p> | <p>낮음: SKU별 정상 데이터로 별도 모델 훈련 또는 domain adaptation 필요.</p> |

1) 구현 난이도: 제안 방식은 영상 처리와 간단한 통계 계산으로 구성되어 구현이 비교적 용이합니다. OpenCV 기반 렌즈 검출, 픽셀 평균 계산 등은 표준 라이브러리로 가능하여, 하나의 Vision 엔지니어만으로도 빠른 프로토타이핑이 가능합니다. 반면 딥러닝 기반 방식들은 사전 학습된 모델 사용 및 추가 튜닝이 필요합니다. 예를 들어, PatchCore/PaDiM은 ResNet 등 사전학습 CNN의 특징을 추출하고 메모리 또는 분포모델 구축 단계가 필요합니다. 이러한 구현은 공개된 코드(Anomalib 등 라이브러리 ⑫)를 활용하면 수월해졌으나, 여전히 ML 엔지니어의 전문 지식이 요구됩니다. AutoEncoder나 Diffusion 모델은 아예 별도 모델 학습 단계를 거쳐야 하므로, 데이터 수집/전처리부터 네트워크 학습, 하이퍼파라미터 튜닝까지 개발 난이도가 높습니다. 특히 Diffusion 기반 접근은 최신 연구로 코드 및 노하우 축적이 적어, 구현 리스크가 크다고 볼 수 있습니다.

2) 설명가능성(XAI): 제안 방식은 결과 해석이 가장 쉽고 명확합니다. 각 렌즈에 대해 산출된 ΔE 값과 zone별 색 편차, 그리고 어느 영역이 기준 대비 벗어났는지가 수치와 그래프로 제공되므로, 비전공자도 이해하기 쉬운 리포트를 생성할 수 있습니다. 예를 들어 “엣지 영역 색차 $\Delta E=5.2$ 로 허용치($\Delta E=3$)를 초과, 잉크 혼합부 균일도 불량”과 같이 설명이 가능합니다. 반면 PatchCore나 PaDiM 같은 모델은 출력으로 이상 영역을 하이라이트한 히트맵 정도를 제공합니다 ⑬ . 이는 “이 부분이 이상”이라고는 알려주지만, 구체적으로 어떤 특성이 이상인지 (색상? 패턴? 놓도?) 도메인 지식과 연결해 설명하기 어렵습니다. AutoEncoder나 Diffusion 복원 기법도 입력 대비 차이로 이상을 찾지만, 이상 원인을 정량적 지표로 제시하기 어렵습니다. 또한 규제 산업(의료기기 등)에서는 “왜 불량으로 판정했는가?”를 설명하는 기능(XAI)이 중요해지고 있는데 ⑭ , 이 면에서 규칙 기반 ΔE 판정 방식은 투명성과 신뢰도가 높다 할 수 있습니다.

3) 실시간성(속도): 생산 라인에서는 한 개 렌즈를 수백 ms 이내 처리하는 실시간성이 요구됩니다. 제안 방식은 연산이 간단하여 이미지 1장을 数十ms 수준에 처리할 것으로 예상됩니다 (렌즈 검출 + 프로파일 계산 + ΔE 비교). 특히 ROI가 렌즈 영역으로 한정되고 1차원 프로파일로 축약되므로, 고해상도 이미지라도 처리 속도가 빠릅니다. PatchCore의 경우, 메모리 뱅크 검색이 병목이 될 수 있으나, 핵심 패치만 추려내는 코어셋 기술 덕분에 1% 패치만으로도 성능 유지 및

200ms 내 추론이 가능함을 보고한 바 있습니다 ⁶. PaDiM은 위치별 다변량 정규분포 계산에 시간이 들지만, 입력 한 장에 대해서는 **Covariance 계산 + Mahalanobis 거리** 연산으로, PatchCore와 비슷한 수준(수백 ms)으로 알려져 있습니다. AutoEncoder는 신경망 순방향 연산 1회로 결과가 나오므로 비교적 빠를 수 있으나, 고해상도 이미지를 처리 하려면 **모델이 커져 속도가 저하될 수 있습니다.** Diffusion 기반 방법은 일반적으로 **수십 회 이상의 반복 denoising** 단계가 필요하여 “느리다”는 것이 큰 약점이었습니다. 다만 최근 연구에서는 **One-Step Denoising** 등으로 이러한 속도 문제를 개선하려는 시도가 있으며 ¹⁰, 여전히 PatchCore 등보다 느리지만 점차 실시간에 근접시키는 추세입니다.

4) 대품종 SKU 대응력: 콘택트렌즈는 디자인(SKU)이 다양하며, 시스템이 **여러 SKU를 혼류로** 검사해야 하는 상황을 가정해야 합니다. 제안된 r-프로파일 방식은 새로운 렌즈 디자인이 나오더라도 **별도의 모델 재학습 없이**, 해당 SKU의 양품(정상) 몇 장만 촬영하여 **LAB 기준값과 허용 ΔE** 등을 설정하면 곧바로 검사에 활용할 수 있다는 장점이 있습니다 ¹⁵ ¹⁶. 즉, **SKU 추가에 대한 비용이 낮고 유연성이 높습니다.** 반면 비지도 딥러닝 방식들은 SKU마다 **정상 데이터로 모델을 “학습”**하거나 **통계분포를 재계산해야 합니다.** PatchCore/PaDiM의 경우 각 SKU별로 별도의 메모리 뱅크나 분포 모델을 유지해야 하므로, SKU 수가 많아지면 **모델 관리 복잡성이 증가합니다.** (하나의 통합 모델로 여러 종류를 다룰 수도 있으나, 서로 다른 패턴을 한 모델이 모두 커버하면 성능이 떨어질 우려가 있습니다.) AutoEncoder나 Diffusion은 더욱이 **디자인마다 새로 네트워크를 학습해야 정상 패턴을 습득하므로, 대품종 대응력이 낮습니다.** 따라서 제품 종류가 많은 산업 환경에서는 초기 설정만으로 바로 적용 가능한 **규칙 기반 접근이 운영 면에서 유리합니다.**

5) 검출 성능 측면: (표의 항목은 아니지만 중요한 비교 요인) 일반적으로 딥러닝 기반 **이상 탐지 정확도**는 전통적 방법 보다 높다고 알려져 있습니다. 실제로 PatchCore, PaDiM 등은 **MVTec AD** 벤치마크에서 전통 기법 대비 뛰어난 불량 검출 성능을 보이며, PatchCore는 2022년 SOTA 중 하나로 산업계 관심을 모았습니다 ¹⁷. Diffusion 모델 활용 기법은 99%에 육박하는 AUROC을 보여 **사실상 완벽에 가까운 탐지도 달성하고 있습니다** ⁹. 반면 본 제안 방식은 **주로 색상 편차에 한정하여** 를 기반으로 검사하므로, **검출 가능 범위에 한계가 있습니다.** 예를 들어 인쇄 패턴의 형태적인 이상(모양 찌그러짐, 패턴 밀림 등)은 색 분포만으로는 잡아내기 어려울 수 있습니다. 다만 렌즈 패턴이 동심원 계열인 경우, 형태 이상이 곧 색상의 위치 이상으로 나타나기 때문에 어느 정도 색상 분석으로 감지 가능하리라 기대합니다 ¹⁸. 또한 인쇄 도트 누락, 농도 불균일 등도 색상 편차로 간접 평가 가능하다고 보고되었습니다 ¹⁹ ²⁰. 그럼에도 **복잡한 패턴** (예: 꽃무늬)으로 확대 적용하려면 색상 분석만으로는 어려워질 가능성성이 있습니다. 이런 경우 **딥러닝 이상 탐지와의 결합이 필요하며, 실제로 기존 제안서에서도 향후 비지도 이상 탐지 모델(PaDiM, PatchCore)이나 Diffusion 복원 기법을 추가 도입해 형태/패턴 이상까지 자동 검출하는 확장안을 언급하고 있습니다** ²¹.

요약: 현재 검사 대상인 동심원 패턴 렌즈 품질 관리에는, **설명 가능하고 빠르며 유지보수 쉬운 r-프로파일 색상분석** 방식이 적합합니다. 이는 초기 구축 비용과 노력 대비 **실용적인 성과를 낼 확률이 높습니다.** 경쟁 기술인 PatchCore, PaDiM 등은 **일반적인 이상 탐지 능력은 뛰어나나**, 우리 응용에 바로 쓰기에는 **데이터 준비, 모델 복잡도, 도입 비용** 면에서 부담이 있습니다. 특히 **전문 인력 확보, 충분한 정상 데이터 수집이 선결되어야 하고**, 현장의 비전공자가 바로 결과를 해석하기 어려울 수 있습니다. 그러나, **장기적 관점에서** 제품 패턴이 다양해지거나 더 높은 수준의 불량 검출이 필요해지면, 이러한 딥러닝 기반 솔루션을 **보조 도구로 통합하는 방향을 고려할 수 있습니다.** 예를 들어, 1차적으로 r-프로파일 방식으로 색상 검사를 하고 2차로 PatchCore로 미처 발견 못한 패턴 이상을 잡아내는 **혼합 전략도 가능합니다** ²². 현 단계에서는 **도메인에 특화된 규칙 기반 방법으로 빠르게 ROI(Return on Investment)를 실현하고**, 추후 필요 시 고도화 기술을 점진적으로 적용하는 것을 권장합니다.

3. 실제 도입을 위한 개발 리소스 및 프로세스

이 절에서는 제안된 시스템을 현실의 생산 현장에 도입하기 위해 필요한 **개발 인력, 기간, 자원과 단계별 추진 계획**을 정리합니다. 또한 **PoC(개념검증)** 단계에서 요구되는 데이터 및 장비, 그리고 운영 단계의 시스템 연동/유지보수 고려사항을 다룹니다.

3.1 필요 인력 및 역할

원활한 개발을 위해서는 **다양한 분야의 협업**이 필요합니다. 아래와 같이 인력 구성과 담당 역할을 제안합니다:

- **머신러닝/비전 엔지니어 (1명)** – 전체 영상 처리 알고리즘 및 모델 개발 리드. 렌즈 검출, 색상 프로파일 계산, ΔE 판정 로직, (추후 딥러닝 모델 검토까지) 기술 구현을 담당합니다.
- **소프트웨어/UI 엔지니어 (1명)** – 검사 프로그램의 UI 개발 및 시스템 통합 담당. 현장 사용자가 결과를 확인할 수 있는 대시보드 또는 GUI 구현, 카메라 인터페이스, 데이터베이스 연동, 리포트 생성 기능 등을 맡습니다.
- **프로젝트 매니저/도메인 전문가 (1명)** – 콘택트렌즈 제조 공정 및 품질 기준에 대한 이해를 바탕으로 프로젝트를 총괄. 요구 사항 수집, 현장 테스트 조율, 일정 관리 및 문서화. (필요시 품질팀에서 겸임 가능)
- (옵션) **ML 연구 엔지니어 (추가 0~1명)** – 딥러닝 기반 anomaly detection 기법의 실험/도입을 병행할 경우 투입. PatchCore 등 벤치마킹, 성능 향상 방안 연구. (초기 PoC에는 필수 아님)

소규모 프로젝트로서 위 인력이 겸임될 수도 있지만, **적어도 2명 이상의 핵심 개발자를** 두어 한 명이 Vision 알고리즘, 한 명이 UI/시스템을 책임지는 것을 권장합니다. 추가로, **현장 테스트** 단계에서는 제조 현장의 ICT 엔지니어나 QA 담당자의 시간이 일부 투입되어, 검사 시스템을 기준 장비와 연결하거나, 검사 결과의 품질 평가 피드백을 주는 것이 필요합니다.

3.2 개발 일정 및 마일스톤

개발은 **4단계 마일스톤**으로 계획되며, 각 단계별 목표와 산출물을 정의합니다. 예상 소요 기간은 단계별 병행 여부와 인력 투입에 따라 달라지지만, **전체 4~5개월 내외로 완수를 목표로 합니다**. 아래는 권장 일정의 예시입니다:

1. **1단계 – 알고리즘 프로토타입 (예상 4주):** 핵심 r-프로파일 계산 및 zone 분할 알고리즘의 **기능 검증** 단계입니다. 콘솔/노트북 환경에서 단일 이미지에 대해 전체 파이프라인이 동작하는지를 확인합니다.
2. 주요 작업: 렌즈 중심/반경 검출 구현, r-profile 생성 및 LAB 변환, 임시 ΔE 기준으로 테스트. 몇 장의 샘플 이미지로 A/B/C 및 혼합 영역이 직관적으로 잘 구분되는지 시각화해 검토 ²³.
3. 산출물: Jupyter 노트북 보고서 또는 간단한 콘솔 프로그램. (결과 예: 원본 이미지에 zone 경계선 표시, r vs LAB 곡선 그래프, ΔE 계산 출력)
4. **2단계 – Zone 자동 분할 및 SKU 기준 설정 (예상 4주):** 다양한 정상 샘플을 활용하여 **SKU별 기준값**을 자동으로 산출/관리하는 기능 구현.
5. 주요 작업: r-프로파일의 **변곡점 검출 알고리즘** 개발 (예: ΔE 연속곡선에서 국소 극댓값 찾기) ²⁴, 잡음으로 인한 불필요 경계 제거 위한 평활화. 여러 장의 양품 이미지를 입력받아 zone 경계를 **자동 설정**하고 각 zone의 평균 LAB 및 편차를 계산하여 해당 SKU의 **기준 데이터(JSON 등)**로 저장 ²⁴ ²⁵. UI 또는 스크립트를 통해 “이 샘플들을 기준으로 등록”하는 인터페이스 제공.
6. 산출물: SKU 설정 파일 생성 기능, 변곡점 기반 자동 구간화 모듈 완성. 간단한 설정 UI/툴 (예: PyQt 또는 CLI 스크립트).
7. **3단계 – 품질 판정 로직 고도화 (예상 4주):** 현장 도입 수준의 **정확도와 안정성 확보** 단계입니다. 다양한 실제 생산 샘플(양품/불량)을 수집하여 판정 기준을 최적화합니다.
8. 주요 작업: zone별 허용 ΔE 임계값 세부 조정 및 혼합 zone의 허용 편차 기준 설정 ²⁶ ²⁷. 실제 발생 가능한 불량 유형 (잉크 번짐, 인쇄 미스 등)에 대한 테스트를 실시하여 검출률(민감도) 향상과 오탐률(특이도) 균형 맞추기 ²⁸. 필요 시 조명 변화나 이미지 잡음에 대한 견고성 개선(전처리 강화 등).
9. 산출물: 시험 결과 보고서 (양품/불량에 대한 ΔE 분포, 오탐/미탐 사례 분석), 튜닝된 판정 파라미터 세트. 이 단계에서 **프로토콜**도 마련: 새로운 불량 사례가 발견될 때 기준을 어떻게 업데이트할지 가이드.

10. 4단계 – 사용자 인터페이스 및 현장 도입 준비 (예상 4주): 현장에서 사용 가능한 형태로 시스템을 **포장 및 통합**하는 최종 단계입니다.

11. 주요 작업: 검사 소프트웨어의 **GUI 개발** (또는 기존 공정 PCソフト에 결과 출력 연동) ²⁹. 검사 시작/중지, 이미지 실시간 표시, NG 발생 시 알람 등의 **UX 설계**. SKU별 설정 추가/수정 및 백업 기능 구현 ³⁰. 검사 결과 리포트(예: PDF 또는 화면표시) 포맷 확장 – SKU, 로트번호, 검사 시간, zone별 ΔE 값과 NG 여부 등을 표기 ³⁰ ³¹. 또한 **장비 사양서 및 운영 가이드** 작성: 사용 카메라/렌즈 스펙, 해상도와 배율, 조명 종류와 밝기, 설치 방식, 교정 방법 등을 문서화 ³¹.

12. 산출물: 완성된 검사 프로그램(실행 파일 또는 어플리케이션) 및 사용자 매뉴얼 초안. 현장 설치 및 시운전 계획.

(상기 일정은 2명 팀 기준의 예상입니다. 인력이 추가되면 2~3단계를 병행하거나 기간을 단축할 수 있습니다. 반대로, PoC에서 예기치 못한 문제 발생 시 일정이 늘어날 수 있습니다.)

3.3 PoC 테스트 데이터 및 장비 요건

데이터(샘플) 요건: 시스템 성능 검증을 위해 **충분한 이미지 샘플**이 필요합니다. SKU별로 **양품(정상)** 렌즈 이미지 약 30장 이상을 추천합니다. 이 정도면 색상 변이의 통계적 범위를 파악하고 ΔE 임계값을 설정하는 데 유용합니다. 또한 가능한 대로 **불량 샘플** (색상 불량 혹은 인쇄 불량)도 확보해야 합니다. 초기에는 불량 데이터를 많이 모으기 어렵다면, **의도적으로 결함을 유발한 샘플이나 합성 데이터**도 활용합니다. 예를 들어 잉크 농도를 변화시킨 테스트 렌즈, 인쇄 공정에서 일부러 번짐이나 누락을 발생시켜 본 샘플 등을 제작해 볼 수 있습니다. 최소 5종 이상의 대표 불량 사례에 대해 각 수십 장씩 이미지를 얻는 것이 바람직합니다. PoC 단계에서는 모든 불량 유형을 커버하기 어렵겠지만, **검출해야 할 주요 케이스**(예: 색상 치우침, 경계 번짐, 패턴 밀림 등)를 선정해 집중 검증합니다.

장비(하드웨어) 요건: - 카메라 및 광학: 콘택트렌즈의 세밀한 패턴과 색 분포를 얻기 위해 **고해상도 카메라**가 필요합니다. 최소 5메가픽셀급 (해상도 예: 2448×2048) 이상을 권장하며, 렌즈 한 개가 이미지에서 지름 1000픽셀 이상으로 표현되도록 촬영해야 미세한 색상 변화를 포착할 수 있습니다. 렌즈 촬영시 왜곡을 줄이기 위해 **매크로 렌즈** 또는 적절한 배율의 광학계를 사용하고, **초점을 정확히 맞춰야 합니다**.

- 조명: 색상 분석에서는 조명 조건이 매우 중요합니다. **균일하고 재현성 있는 조명** 환경을 구축해야 하며, **색온도도 일정해야 합니다**. 일반적으로 **링형 LED 조명**을 활용하여 렌즈를 주변에서 고르게 비추거나, **돌 조명**으로 반사광을 최소화하는 방식을 고려합니다. 조명의 광량은 카메라 셔터속도/조리개와 조합해 이미지가 **과도 노출이나 암부 손실 없이** 또렷하게 나오도록 설정합니다. 또한, **광원 색온도 (예: 5000K)**와 **화이트 밸런스 교정**을 통해 이미지 색값이 기준 LAB 값과 대응되도록 해야 합니다. (필요시 X-rite ColorChecker 등의 컬러 차트를 촬영해 **색 보정을 적용**) - 컴퓨팅 장비: 제안 방식 자체는 **일반 산업 PC (IPC)** 수준에서도 충분히 실시간 동작이 가능합니다. 예를 들어 Intel Core i7급 CPU에서도 한 장 이미지 처리에 수십 ms면 족하므로, GPU가 필수는 아닙니다. 다만 향후 PatchCore 등 딥러닝 모델 통합을 고려한다면 **NVIDIA GPU** (예: RTX 시리즈) 탑재를 권장합니다. 개발 단계에서는 표준 데스크탑 PC로 진행하되, 최종 설치는 **공장 환경에 적합한 팬리스 IPC**로 옮기는 것을 검토합니다.

- 기타: 렌즈를 촬영하기 위한 **지그 혹은 트레이**가 필요합니다. 컨베이어 상에서 렌즈가 임의 각도로 놓여도 문제없도록 설계되었지만, 검사 영역에 항상 렌즈가 안정적으로 위치하도록 기계적 고정 장치가 있어야 합니다. 트리거 신호 (렌즈 도착 감지 센서 등)와 카메라 촬영 제어를 연계하는 부분도 구성합니다.

3.4 시스템 통합 및 유지보수 고려사항

SKU 관리 및 MES 연동: 본 시스템은 다양한 SKU의 렌즈를 검사할 수 있어야 하므로, **SKU별 검사 기준 관리**가 중요합니다. 이를 위해 **중앙 관리 방식**을 채택합니다. 예를 들어 **SKU Database** 혹은 **설정 파일 디렉토리**를 두고, 각 SKU 코드에 해당하는 목표 LAB 값, ΔE 허용치, zone 경계 정보 등을 저장합니다. 검사 시작 시 현재 생산되는 SKU를 시스템에 입력(또는 바코드/QR 코드로 스캔)하면, 프로그램이 자동으로 해당 SKU의 설정값을 불러와 적용하도록 합니다. 이렇게 하면 새로운 SKU가 출시될 때 **간단히 기준 등록**만으로 검사 준비가 가능합니다. SKU 설정 변경 이력도 관리하여, 이후 문제 발생 시 어떤 기준으로 검사했는지 **이력 추적이 가능하도록** 설계합니다.

제조 실행 시스템(MES) 또는 품질관리 시스템과의 **데이터 연동**도 고려합니다. 검사 결과 (OK/NG 판정, ΔE 값 등)을 실시간으로 **MES에 전송**하면, 공정 단계별로 제품 품질을 한눈에 모니터링하거나 **불량률 집계**를 자동화할 수 있습니다.

또한 LOT 단위로 색상 품질 트렌드를 분석하여, 예를 들어 “최근 3일간 엣지 영역 ΔE 값 평균이 서서히 상승” 등의 정보를 얻어 선제적 조치를 취할 수도 있습니다 ³². 이는 생산 공정 조건 변화나 잉크 배치 변화에 따른 미세한 품질 변동도 감지하여, **프로세스 최적화**에 기여할 것입니다.

지속적인 유지관리: 시스템 도입 후에는 정기적인 검교정 및 성능 점검이 필요합니다. 조명 밝기나 카메라 센서 특성이 시간에 따라 변할 수 있으므로, 주기적 캘리브레이션(예: 주 1회 색상 표준차트 촬영)으로 기준 색상 값을 보정해야 할 수 있습니다. 소프트웨어 측면에서는, 신규 불량 사례가 발견되면 그것을 검출할 수 있도록 알고리즘을 개선하거나 임계 값을 조정하는 피드백 프로세스를 마련합니다. 이때를 대비해, NG 판정된 샘플의 이미지와 프로파일 정보를 자동 저장해 두는 로깅 기능을 넣었습니다 ³³ ³⁴. 축적된 NG 샘플 데이터를 주기적으로 분석하여, 오탐이라면 기준을 완화하거나 미탐이라면 기준을 강화하는 등의 **튜닝 작업**을 수행합니다. 이러한 유지보수 작업은 월 1회 정기 리뷰 형태로, 품질 엔지니어와 시스템 개발자가 함께 데이터 확인 후 업데이트하는 절차를 제안합니다.

만약 향후 딥러닝 기반 이상 탐지 모듈을 추가하는 경우(예: 고난이도 불량 검출 보조), 해당 모듈에 대한 **모델 재학습** 주 기나 **데이터 관리**도 계획해야 합니다. 이는 별도의 R&D 과제로 다를 수 있으며, 초기 단계에서는 현재 규칙 기반 시스템이 **stable**하게 운영되는 것이 우선입니다.

4. 결론 및 권고

본 개선 제안서는 **콘택트렌즈 색상 검사 시스템**을 성공적으로 개발하고 도입하기 위한 종합적인 평가와 계획을 제시했습니다. **동심원 r-프로파일 기반 색상 분석**이라는 도메인 지식 활용 접근법은 구현이 쉽고 설명력이 높으며, 다품종 환경에 적응하기 유용한 솔루션입니다. 경쟁하는 최신 기술들과 비교한 결과, 현 시점에서는 제안 방식이 **실용성과 효율** 면에서 유리하며, 특히 **색상 품질 관리**라는 명확한 목적에 잘 부합한다고 판단됩니다. 딥러닝 이상 탐지 기법들은 높은 성능 잠재력을 지니지만, **데이터 준비, 전문성, 리소스 투입** 측면에서 투자 대비 효과를 신중히 따져봐야 합니다. 그러므로 초기에 제안 방식을 도입하여 **빠른 효과**를 얻고, 점차 시스템 이해도가 높아지면 **고도화 옵션**으로서 PatchCore, Diffusion 등을 검토하는 **단계적 접근**을 권장합니다.

요약하면, 이 시스템이 구현되면 얻을 수 있는 기대 효과는 다음과 같습니다:

- **정량적 색상 품질관리 달성:** ΔE 수치 기반의 객관적 검사로, 사람 눈에 의존하던 판단을 계량화합니다. 작은 색상 변동도 놓치지 않고 기록하므로, 잉크 배합이나 인쇄 공정 개선에도 활용할 수 있습니다.
- **초기 투자 대비 높은 ROI:** 기존 생산 라인에 큰 변경을 가하지 않으면서 소프트웨어 업그레이드만으로 품질 수준을 높입니다. 교육을 받지 않은 작업자도 UI를 통해 불량 여부를 쉽게 판단할 수 있어 **현장 적용이 용이**합니다.
- **향후 확장 용이성:** 시스템 구조가 모듈화되어 있어, 이후 새로운 검사항목(예: 투명부 기포 검사, 패턴 정합 검사 등)을 추가하기 수월합니다. 특히 r-프로파일 결과와 딥러닝 모델 결과를 **융합**하는 등 확장 연구도 가능하며 ³⁵, 이는 회사의 **검사 자동화 기술 역량**을 한층 강화할 것입니다.

마지막으로, 성공적인 프로젝트 수행을 위해서는 **경영진 및 현장 부서의 지속적인 지원**이 중요합니다. 개발 단계에서 적절한 샘플 제공과 피드백, 도입 단계에서의 교육과 숙련도가 필요합니다. 본 문서의 개선안을 바탕으로, 관련자들이 명확한 방향 아래 협력한다면, 본 콘택트렌즈 색상 검사 시스템은 **기간 내 목표 성능을 달성하고 생산 라인에 안착**할 것으로 기대됩니다. 품질 관리의 디지털 전환이라는 **사업적 성과**도 함께 거두길 바랍니다.

1 2 12 13 [Tech Blog] Overview of Anomaly Detection Technologies | TOMOMI RESEARCH
<https://www.tomomi-research.com/en/archives/2968>

3 4 6 11 17 Anomaly detection in images using PatchCore
<https://dataroots.io/blog/anomaly-detection-in-images-using-patchcore>

5 22 How to Detect Visual Anomalies. Unsupervised Anomaly Detection with... | by Jacob Marks, Ph.D. | Voxel51 | Medium

<https://medium.com/voxel51/how-to-detect-visual-anomalies-96ca856b63d1>

7 8 14 딥러닝 이상 탐지 지금 꼭 알아야 할 핵심 - 세이지 SAIGE, AI that works.

<https://saige.ai/blog/deep-learning-anomaly-detection/>

9 [Anomaly Detection] DDAD - Anomaly Detection with Conditioned Denoising Diffusion Models 논문리뷰

<https://velog.io/@tnqlscodms/Anomaly-Detection-DDAD-Anomaly-Detection-with-Conditioned-Denoising-Diffusion-Models-%EB%85%BC%EB%AC%B8%EB%A6%AC%EB%B7%BO>

10 [Paper Review] DiffusionAD: Norm-guided One-step Denoising Diffusion for Anomaly Detection – DSBA

<https://dsba.snu.ac.kr/seminar/?mod=document&uid=2791>

15 16 18 19 20 21 23 24 25 26 27 28 29 30 31 32 33 34 35 콘택트렌즈_색상_검사_시스템_개발_플랜_제안서.md

file:///file_0000000302472078b281a529ca69e4a